

Interactions Cryptographie Historique et IA: Modèle de reconnaissance du type de chiffrement d'images de documents chiffrés manuscrits

Maé DUGOUA-JACQUES

Superviseure: Cécile PIERROT, équipe Caramba, projet Back In Time

Contents

1	Introduction	2
1.1	Remerciements	2
1.2	Contexte Académique	2
1.3	Objectifs	2
1.4	État de l'Art	2
2	Description des données	3
2.1	Base de données originale	3
2.2	Interdisciplinarité: connaissances expertes	4
3	Pistes explorées	5
3.1	Vision-Language Model (VLM)	5
3.2	Ontologies	5
3.3	Reconnaissance des manuscrits non-chiffrés	6
4	Bilan d'implémentation	8
4.1	Schéma d'architecture	8
4.2	Reconnaissance des manuscrits chiffrés // documents non chiffrés // autres documents	9
4.3	Obtention des données tabulaires	10
4.4	Déduction du type de chiffrement	11
5	Étapes additionnelles	12
5.1	Reconnaissance des espaces et des points de scission de token	12
5.2	Pipeline additionnelle: cross encoder (Lei et al., 2022)	14
6	Stack fonctionnelle prévisionnelle	16
7	Limitations	16
8	Conclusion	16
A	Déclaration d'utilisation d'outils d'intelligence artificielle	17
B	Glossaire	17

List of Figures

1	Ontologie de connaissances expertes: Type de chiffrements entre 1400 et 1950 (non-exhaustif) Image en clair	6
2	Schéma complet d'architecture du système CipherTypeFinder : Image en clair	8
3	Vue de l'arbre de fichiers du projet Github	10
4	(1) EHNE, <i>Télégramme Zimmermann, 16 janvier 1917</i> , chiffrement de type machine	13
5	(2) Maison d'éducation surveillée d'Eysses, <i>Lettre chiffrée envoyée à un pensionnaire du « bain pour enfants » en 1931</i> , chiffrement de type nomenclature	13
6	Encadré en rouge: le module à insérer au sein de la phase de prétraitement de la pipeline globale 2	14
7	Encadré en rouge: cross encoder venant remplacer une partie de la pipeline existante	15

1 Introduction

1.1 Remerciements

Je remercie personnellement Cécile Pierrot, mon encadrante pendant ce stage, et par extension l'équipe Caramba pour les nombreux savoirs qu'elle a pris le temps de me transmettre, son soutien et pour la liberté de création qu'elle m'a laissée dans ce travail.

Je remercie le Loria de m'avoir une nouvelle fois accueillie et de me permettre de progresser d'année en année dans un domaine qui me porte.

Je remercie enfin l'ensemble des équipes de maintenance et d'accueil du Loria pour leur professionnalisme sans faille et le soin qu'elles prêtent aux membres des équipes.

1.2 Contexte Académique

Ce stage non obligatoire en fin de première année de Master Traitement Automatique des Langues (NLP/-TAL) s'est déroulé entre le 29 juin et le 15 août 2026.

La convention a été signée avec l'IDMC (Institut du Digital, Management et Cognition) après des entretiens préliminaires entre le stagiaire et l'encadrant.

1.3 Objectifs

Le sujet de ce stage était la création d'une solution d'automatisation de l'identification du type de chiffrement de manuscrits chiffrés, pris en photo et envoyés via des sources externes.

Ce projet a été réalisé dans le cadre du projet Back-In-Time de l'équipe Caramba, Loria, Nancy. Cette demande provient de la particularité des données traitées par certaines équipes de cryptographes, envoyées de tous horizons géographiques et par des personnes de toutes professions et spécialités (Historiens, criminologues, collectionneurs, particuliers...).

La création de ce modèle est motivée par la variabilité en qualité et en nature des documents reçus et par la forte demande qu'expérimentent les équipes. En effet, contrairement aux idées reçues, il existe encore aujourd'hui de très nombreux documents chiffrés en circulation et de nombreuses personnes, professionnelles ou amatrices, qui travaillent activement sur ce type de données historiques. En considérant le faible nombre d'experts en ce domaine, la charge de travail induite devient incompatible avec leurs autres activités de recherche.

L'analyse de ces documents a donc un prix humain et technique très important. Ainsi cette automatisation permet aussi de ne tester que les algorithmes de déchiffrement les plus probables et ainsi accélérer le processus complet de déchiffrement et de réduire son coût d'un point de vue énergétique et financier.

1.4 État de l'Art

Comme mentionné précédemment, la cryptographie historique est considérée comme un domaine de niche comportant très peu d'experts en France et dont le mode de transfert de connaissance se fait principalement de main à main, lors d'expériences professionnelles touchant au domaine et par la mise en contact avec un de ces experts ou son projet.

Le concept de "type de chiffrement" en cryptographie utilisé dans ce travail permet notamment de généraliser un processus de chiffrement et donc de le corréliser avec un processus/algorithme de déchiffrement. Cependant du point de vue de la discipline d'historien, le "type de chiffrement" permet plutôt d'établir un lien basé sur des caractéristiques temporelles, géographiques ou historiques...

Ces spécificités de définition de termes rendent complexe la collaboration essentielle entre les parties malgré les tentatives de consensus faites (Mikhalev et al., 2023)

Pourtant, la cryptographie historique est une clé pour la compréhension de l'histoire. En effet, les messages chiffrés constituent une source clé d'informations importantes lors d'événements piliers du passé. La quantité de messages encore aujourd'hui chiffrés représente donc une source indéniable de savoirs encore inconnus d'un point de vue historique mais aussi sociologique.

Dès lors, déchiffrer ces messages et savoir pour quelles raisons ils ont pu l'être, que ce soit pour cacher entièrement une information ou retarder sa compréhension en temps de guerre par exemple, devient une tâche importante malgré la complexité de la variabilité des méthodes de chiffrement de l'époque.

C'est notamment en raison de cette variabilité et de l'inconstance dans l'utilisation des types de chiffrement que les systèmes d'intelligence artificielle deviennent essentiels à la résolution de ces problèmes. (Foxon, 2025)

2 Description des données

2.1 Base de données originale

Le corpus utilisé dans ce projet est extrait de la base de donnéesB du **DECRYPT PROJECT** (Megyesi et al., 2020): DECRYPT Records.

Cette base de données est alimentée et annotée de façon spontanée. Elle comporte à la fois des textes chiffrés, leur équivalent déchiffré mais aussi des clés de déchiffrements...

Cette base de données dispose d'une API permettant de questionner la base de données depuis un script. 4.3

Cette base de données est sous licence Créative Commons CC-by 4.0. Cette licence permet son utilisation dans ce projet afin de créer notre corpus. Son utilisation requiert l'autorisation des auteurs et l'utilisation d'un identifiant et d'un mot de passe fournis par ceux-ci sur demande.

Les données et notamment les annotations de celle-ci sont une source conséquente d'approximations dans ce projet. En effet, les documents étant chargés de façon spontanée il existe des incohérences dans les annotations associées à ceux-ci. Notamment quant au lieu d'origine, que l'on retrouve sous plusieurs formes, certains types de chiffrements indiqués qui peuvent paraître incohérents...

Le corpus final que nous avons pu extraire pour notre projet regroupe:

- 413 pages de manuscrits chiffrés exploitables (1.7GB)
- 413 fichiers .json B, 1 pour chacune des pages comportant:
 - la région d'origine (NULL possible si "ville d'origine" not NULL)
 - la ville d'origine (NULL possible si "région d'origine" not NULL)
(Les deux sont équivalent. Pour certains documents la provenance est indiquée sur l'un, et pour un autre sur l'autre)
 - la date
 - le type de chiffrement
 - les types de symboles utilisés (NULL possible)
 - la langue du texte déchiffré (NULL possible)

La région et la ville d'origine sont des strings et peuvent être des villes ou des pays. (la ville est considérée en priorité pour maximiser les chances d'uniformisation de l'annotation)

La date est un nombre représentant l'année de création.

Le type de chiffrement est exprimé sous forme d'indices:

- 1: Substitution simple

- 2: Substitution Homophonique
- 4: Polyalphabétique
- 5: Nomenclature
- 7: Polyphonique

Le type de symbole utilisé est sous la forme d'indices:

- 8: Signes graphiques
- 3: Alphabet
- 1: Numeriques

La langue du texte déchiffré est une string. Seules certaines langues sont soutenues par le système:

- french
- portuguese
- german
- spanish
- latin
- italien
- english

2.2 Interdisciplinarité: connaissances expertes

Ce travail est axé autour de l'interdisciplinarité et la rencontre entre de multiples spécialités: la cryptographie, l'histoire, la linguistique, les mathématiques et l'informatique.

Ce modèle a donc nécessité en amont une phase de discussion entre les acteurs des différents domaines pour comprendre les enjeux de chacun et permettre l'élaboration d'un modèle fiable et efficace pour toutes les parties utilisatrices.

Cette phase a aussi permis de concevoir certaines documentations sur l'état de l'art en cryptographie historique et notamment sur les caractéristiques de chaque type de chiffrement.

Ce modèle n'aurait en aucun cas pu être créé sans l'appui d'experts. En effet, l'utilisation d'un Convolutional Neural Network (CNN) simple complémenté par un réseau neuronal entraîné sur les métadonnées B n'aurait pu aboutir à cause de plusieurs points:

- L'utilisation d'un modèle uniquement basé sur les images brutes de manuscrits risquerait d'aboutir sur une fixation du modèle sur des caractéristiques non pertinentes (couleur du papier, saturation de l'image, qualité de l'image...)
- Toutes les métadonnées présentes dans la base d'entraînement ne sont ni pertinentes ni propres. Cela pourrait aussi entraîner une hyperfixation du modèle sur des caractéristiques non importantes malgré une Analyse en Composantes Principales (PCA).
- La plupart des métadonnées présentes dans la base de données ne pourront pas être restituées par un utilisateur final. En effet les documents voués à être analysés par le modèle sont des documents inconnus avec souvent beaucoup de zones d'ombre sur leurs origines.

Il est donc impératif pour entraîner le modèle B de comprendre les tenants et les aboutissants du projet Back-In-Time et des disciplines impliquées.

3 Pistes explorées

3.1 Vision-Language Model (VLM)

Étant donné la durée du stage allouée à la construction de ce modèle, il a été envisagé en première instance de créer uniquement un VLM, un modèle basé sur les images, pour déduire des images de manuscrits chiffrés et leur type de chiffrement.

Cependant, comme évoqué précédemment, cette méthode présentait théoriquement peu de chances de fournir des résultats satisfaisants en termes de précision à cause du risque de fixation erronée du modèle. L'utilisation des images de manuscrits brutes comme données d'entraînement furent donc gardées pour deux autres étapes du modèle final:

- Reconnaissance des manuscrits chiffrés // documents non chiffrés // autres documents 4.2
- Comme apport de données complémentaires à la pipeline B développée durant ce stage

3.2 Ontologies

La création d'une ontologie B concernant les connaissances expertes à propos des types de chiffrements existants entre 1400 et 1950 a d'abord été faite dans un but de compréhension et de synthétisation des connaissances expertes.

Celle-ci a ensuite été considérée comme apport direct au modèle sous forme de règles correspondant au paradigme symbolique.

Cette approche a cependant été abandonnée en considérant la variabilité des caractéristiques des types de chiffrements durant cette période.

En effet, malgré l'observation de tendances dans l'utilisation de ces types de chiffrement selon les époques et les localisations, ces phénomènes restent très inhérents à la personne ayant rédigé le manuscrit chiffré et restent sujets à de nombreuses erreurs dans le respect même du type de chiffrement ou de la nomenclature B utilisée par l'auteur, dû au chiffrement manuel des écrits.




Figure 1: Ontologie de connaissances expertes: Type de chiffrements entre 1400 et 1950 (non-exhaustif)
Image en clair

3.3 Reconnaissance des manuscrits non-chiffrés

La reconnaissance des manuscrits non-chiffrés était, dans le cahier des charges, une pièce forte du système à implémenter.

En effet, parmi les documents que les experts en cryptographie historique reçoivent chaque jour, beaucoup d'entre eux ne relèvent pas de leur expertise. Cependant, chacune des pièces envoyées nécessite une attention particulière pour comprendre son potentiel historique. Ce temps dédié peut donc être entièrement perdu quand les écrits étudiés ne relèvent finalement pas du domaine de la cryptographie.

Manuscrit non-chiffré:

Un manuscrit non-chiffré est considéré ici comme un document écrit à la main et semblant chiffré.

Ces manuscrits sont souvent écrits avec des langues peu connues, voire inconnues et des langues écrites utilisant un système logographique et des symboles éloignés des symboles latins.

Ces écritures peuvent souvent présenter très peu d'espaces entre chaque caractère.

Pourtant, cette étape n'a pas pu être pleinement réalisée durant ce stage. En effet, la caractérisation de ces manuscrits non-chiffrés est extrêmement complexe, les experts eux-mêmes éprouvant souvent des difficultés à identifier qu'un manuscrit qu'on leur présente est issu, non pas du chiffrage d'une langue, mais d'une production écrite d'une langue existante directement.

L'unique solution ayant aujourd'hui été imaginée est l'utilisation d'un CNN 4.2 (Partin et al., 2023)

Le problème principal dans cette méthode est l'apport d'images de manuscrits non-chiffrés pour permettre au modèle de converger B correctement.

Une des solutions qui pourrait être envisagée selon les ressources disponibles serait de trouver une base libre de droits d'images de ce type et d'annoter l'ensemble du corpus à la main ou par script.

4 Bilan d'implémentation

4.1 Schéma d'architecture




Figure 2: Schéma complet d'architecture du système **CIPHERTypeFinder**: Image en clair

4.2 Reconnaissance des manuscrits chiffrés // documents non chiffrés // autres documents

Comme abordé précédemment, la première étape du système **CipherTypeFinder** est un CNN entraîné pour reconnaître les manuscrits chiffrés des documents non-chiffrés ou non pertinents.

Ce modèle est disponible et entraîné sur Gitlab. Un Command Line Interface (CLI)B est disponible pour permettre une interaction facilitée avec celui-ci.

Ce premier modèle est entraîné sur:

- 100 images de manuscrits chiffrés disponibles dans notre corpus
- Environ 100 images issues d'une base de données d'images libres de droits (CIFAR 10)
- Au moins 92 images de manuscrits non chiffrés (de préférence logographiques) issues du patching de 46 images de manuscrits non chiffrés.

Le CNN utilisé est un petit réseau de neurones qui repose sur des couches de Conv2D+MaxPooling2D+Dropout pour petit à petit extraire les caractéristiques essentielles de l'image sans pour autant risquer l'hallucination. Le risque pris ici est la différence de caractéristiques nécessaires pour différencier une image aléatoire d'un manuscrit chiffré et une image aléatoire d'un manuscrit non chiffré. Il devient donc complexe d'estimer le bon nombre de couches pour permettre au modèle de converger sur les deux sous-tâches.

Afin de fournir la probabilité finale pour un document d'appartenir au cluster des manuscrits, une couche finale a été ajoutée comprenant une fonction d'activation sigmoïde permettant la création des deux clusters. Le seuil par défaut utilisé pour décider à partir de quelle probabilité indiquée par le modèle un document est, ou n'est pas, un manuscrit chiffré, est décidé par l'utilisateur en appel de fonction. La valeur par défaut est 0.5.

À noter que cette partie de la pipeline n'est pour le moment pas rattachée au reste de celle-ci. Cette partie est en réalité assez indépendante du reste et devra être entraînée séparément pour que son output puisse par la suite être utilisé en input de la seconde partie.

Ce modèle présente aujourd'hui une accuracy de 88%. Résultats étant considérés comme acceptables quant aux faibles risques de sécurités liés à la tâche.

4.3 Obtention des données tabulaires




Figure 3: Vue de l'arbre de fichiers du projet Github

Prétraitement Cette première étape constitue principalement une phase de prétraitement. Elle est nécessaire pour préparer la donnée.

La tâche consiste en l'isolation de chaque caractère des différentes pages du corpus. Pour cela nous utilisons une pipeline déjà implémentée par (Reinares Guerreros, Alejandra et al., 2026). Leur modèle ayant été créé pour être entraîné sur les données extraites de la même base de données que la nôtre, cela nous permet de pouvoir réduire notre temps d'implémentation par la réutilisation de leur code. Une clusterisation des caractères est ensuite opérée dans l'optique d'identifier les symboles identiques toujours selon la pipeline décrite dans l'article précédemment cité. L'indice de position de chaque caractère est aussi sauvegardé à cette étape en vue des prochaines.

Cette approche reste cependant hautement critiquable. En effet, le pipeline implémentée dans le papier cité ci-dessus est conçue pour clusteriser les caractères d'un seul document (≈ 1000 caractères par document).

Cependant, notre pipeline doit traiter 433 364 caractères provenant de 413 documents, augmentant le temps de processing et rendant la tâche d’optimisation de la valeur seuil pour la distance entre les objets des clusters par analyse du silhouette score B presque extrêmement complexe et couteuse.

Conversion de format Cette clusterisation va permettre par la suite de reconstruire pour chaque image de manuscrit une forme équivalente à celui-ci dans un format facilement analysable par ordinateur (.txt).(Michelle Waldispühl, University of Oslo et al., n.d.)

Chaque cluster est associé à un caractère UTF-8. Chaque image de manuscrit est ensuite reconstituée sous forme .txt en suivant l’enchaînement des caractères originaux et en les remplaçant par le caractère UTF-8 correspondant en utilisant les index conservés dans l’étape précédente.

Statistiques À partir des documents .txt obtenus dans les étapes précédentes, des statistiques sur la répartition des caractères ont pu être faites à partir d’algorithmes élémentaires.

Ces algorithmes nous permettent d’obtenir 3 différentes données, ensuite conservées sous forme tabulaire (.CSV):

- **Alphabet size:** Nombre de caractères uniques dans tout le document
- **Symbols frequency:** Fréquence de chaque caractère dans le document
- **Index of coincidence difference:** Différence entre l’indice de coïncidence (IC) B du document et celui de la langue de référence indiquée pour ce document.

Utilisé uniquement dans le cas où la langue de référence est indiquée.

Les statistiques étudiées ont été décidées par un travail conjoint avec des experts en cryptographie historique et selon l’étude des méthodes manuelles existantes de déduction du type de chiffrement des manuscrits.

4.4 Déduction du type de chiffrement

La dernière partie de la pipeline existante utilise un MultiLayers Perceptron Classifier (MLPClassifier) afin de traiter les données tabulaires déduites par la pipeline précédente ainsi que les métadonnées qui pourront, à terme, être référencées par l’utilisateur directement en même temps que le document qu’il souhaite soumettre à l’équipe.

Ce modèle a été choisi pour répondre à ce problème en raison de la non-linéarité de celui-ci. En effet, sous certains aspects, il peut sembler que la déduction du type de modèle en fonction de certaines des caractéristiques du texte est linéaire. Or, ce n’est pas le cas en raison de la présence de nombreuses erreurs de chiffrement à cause de la non-automatisation de ceux-ci et de la présence d’outliers liés au fait que ces textes chiffrés ne suivaient aucune norme établie.

L’utilisation d’un MLP Classifier s’est donc révélée indispensable pour une classification multilabels efficace.

En effet un manuscrit ne peut pas être associé avec certitude à un chiffrement, voire, peut appartenir à des groupes et leurs sous-groupes de chiffrement. Il est donc nécessaire de fournir à l’expert en cryptographie tous les labels possibles ainsi que leur degré de confiance (exprimé en %), pour lui permettre une décision éclairée quant au choix de son algorithme de déchiffrement.

Détails techniques Le modèle actuel est entraîné via le serveur Biscotte (Poweredge R7525, Dell) de l'équipe Caramba, Loria, Nancy.

Il demande 35 heures d'entraînement. Pour cause de contraintes techniques, toute machine entraînant le modèle via le serveur Biscotte doit rester au laboratoire, allumée. Le programme doit être lancé via une invite de commande Tmux. Ces contraintes techniques pourraient être, à l'avenir, largement réduites par une demande d'accès au serveur Grid5000 pour permettre un meilleur confort pour le développeur lors de l'entraînement du modèle.

La vitesse d'entraînement est largement augmentée par des imprécisions dans la structure du code et dans la réutilisation de modules existants non-adaptés (*ex: l'autoencodeur, créé par (Reinares Guerreros, Alejandra et al., 2026), ne tourne que sur un Central Processing Unit (CPU) B, ayant été à l'origine conçu pour des petits jeux de données. Une piste d'amélioration pourrait être la refonte de ces modules*)

5 Étapes additionnelles

Certaines étapes ou certains modules ont été architecturés pendant ce projet sans pouvoir être implémentés. Ces étapes sont complémentaires à la pipeline existante et constituent un levier d'amélioration déterminant pour augmenter les capacités du modèle.

5.1 Reconnaissance des espaces et des points de scission de token

Ce premier point est déterminant spécifiquement pour les types de chiffrement plus modernes, comme le chiffrement machine ou les types de chiffrements utilisant une nomenclature.

En effet la présence de séparateurs (espaces, points, virgules) peut indiquer la forte probabilité d'observer un chiffrement de type machine ou nomenclature selon le nombre d'unités par regroupement de caractères. Développer un outil pour identifier ce genre de phénomène semble donc une action significative pour améliorer les performances du modèle.

CLASS OF SERVICE DESIRED
☒ Day Telegram
☐ Night Telegram
☐ Night Telegram
☐ Night Telegram

WESTERN UNION
TELEGRAM
 NEWCOMB CARLTON, PRESIDENT

Send the following telegram, subject to the terms on back hereof, which are hereby agreed to

GERMAN LEGATION
 MEXICO CITY

via Galveston
 JAN 19 1917

130 13042 13401 8501 115 3528 416 17214 6491 11310
 18147 18222 21560 10247 11518 23677 13605 3494 14936
 98092 5905 11311 10392 10371 0302 21290 5101 39695
 23571 17504 11269 18276 18101 0317 0228 17694 4473
 22284 22200 19452 21589 07893 5569 13918 8958 12137
 1333 4725 4458 5905 17106 13851 4458 17149 14471 6706
 13850 12224 6929 14991 7382 15857 67893 14218 36477
 5870 17553 67893 5870 5454 16102 15217 22801 17138
 21001 17388 7446 23638 18222 6719 14331 15021 23845
 3156 23552 22096 21604 4797 9497 22404 20855 4377
 23610 18140 22260 5905 13347 20420 39689 13732 20667
 6929 5275 18507 52262 1340 22049 13339 11265 22295
 10439 14814 4178 6992 8784 7632 7357 6926 52262 11267
 21100 21272 9346 9559 22464 15874 18502 18500 15857
 2188 5376 7381 98092 16127 13486 9350 9220 76036 14219
 5144 2831 17920 11347 17142 11264 7687 7762 15099 9110
 10482 97556 3569 3670

BEHNSTOFF.

Charge German Embassy.

Figure 4: (1) EHNE, *Télégramme Zimmermann, 16 janvier 1917, chiffrement de type machine.*

MAISON
 D'ÉDUCATION SURVEILLÉE
 EYSSES
 (Lot-et-Garonne).

Eysses, le 14 mai 1931

N° matricule : 201235
 Nom : 201235, 13, 4323, 3031, 476, 47, 644, 19, 2028, 31, 6313, 23, 10

Notes

Santé : 16 44 6 31, 3, 12 7 33 4, 4 23, 30 10, 20, 68 23.
 Conduite : 13, 4 33 6 42 12, 13, 7 33 22 44.
 Travail : 13 20 12 64, 23, 9 33 6, 28, 10 13 31 27 80 633
 Instruction : 13 23 23 45, 55, 4 20 28 26 33 6 10, 2.
 13 7 47 13 83, 031, 23 10, 6 33 31, 4 31, 19, 4 20 2, 63 26.
 12 9 13, 9 33, 313, 3031, 12 7 33 12 4, 4 31, 3, 533 3, 13 33 37
 20 12, 633 10 44, 33, 4 31, 23, 33 10, 33 30 13, 67 12 22.
 12 7 33 10 44, 13, 33 23, 30 21 3, 33 37 47 13 53, 43, 4 39 6, 1453
 13, 2 44, 4, 23, 10, 53 3, 4, 7 10 12, 33 12 33 10, 20 63 12 20.

Figure 5: (2) Maison d'éducation surveillée d'Eysses, *Lettre chiffrée envoyée à un pensionnaire du « bain pour enfants » en 1931, chiffrement de type nomenclature.*

Ce module devra être inséré lors de la phase de prétraitement afin que l'autoencodeur soit en capacité de définir une classe pour les caractères d'espacement: points, virgules et espaces blancs. Cependant, ces caractères devront être par la suite encodés à partir de caractères UTF-8 spécifiques pour continuer de les différencier des caractères qui dénotent une unité porteuse de sens.




Figure 6: Encadré en rouge: le module à insérer au sein de la phase de prétraitement de la pipeline globale 2

5.2 Pipeline additionnelle: cross encoder (Lei et al., 2022)

Cette seconde proposition pour l'amélioration de ce modèle vient compléter l'approche mathématique/linguistique de la première pipeline par une analyse de l'image avec l'appui de systèmes de réseaux de neurones.

Ce réseau de neurones devrait être entraîné sur les mêmes images que la partie initiale de la pipeline pour fournir pour chaque image, un vecteur extrait de l'image et un vecteur extrait des métadonnées et statistiques sous forme tabulaire.

Ces deux vecteurs seraient ensuite traités par un TIP/MMCL (Du et al., 2024), un cross encodeur capable de prendre en entrée deux vecteurs de provenance différentes pour faire converger les informations.

Ce nouveau vecteur représentant le document dans son entièreté pourra ensuite être pris en compte par un Recurrent Neural Network (RNN)

Ce RNN est paramétré avec :

- Une fonction d'activation ReLu sur les hidden layers, sélectionnée pour accélérer l'apprentissage et permettre une discrimination plus radicale entre les caractéristiques de deux documents. Ainsi qu'une Softmax (Gao and Pavel, 2018) sur l'output layer pour permettre la classification.
- Une loss function Triplet Loss, de la même façon, pour augmenter l'effet de contraste entre les différentes caractéristiques des documents donnés au modèle. En effet, un des risques existant avec ce jeu de données est la faible distance entre les caractéristiques de deux documents différents. Il

est donc important de maximiser le contraste pour permettre au modèle de différencier les objets appartenant à deux clusters différents.

- Un Optimizer Adam, choisi pour accélérer la convergence.




Figure 7: Encadré en rouge: cross encoder venant remplacer une partie de la pipeline existante

Ce type d'architecture pourrait, a priori, améliorer l'abstraction du modèle de par l'analyse de l'image brute tout en gardant un certain cadre induit par l'analyse des données tabulaires. (Zhao et al., 2024)

6 Stack fonctionnelle prévisionnelle

Correction et optimisation du modèle actuel Le modèle actuel n'est pas entraîné et présente des défauts conséquents d'optimisation qui empêchent de le tester.

L'utilisation de l'algorithme de (Reinares Guerreros, Alejandra et al., 2026) pose certains problèmes de refonte, son utilisation principale ayant été détournée pour être utilisée dans ce projet.

La refonte ainsi que l'entraînement du modèle ($\approx 40h$) représente **2 semaines** de travail à plein temps.

Implémentation de la reconnaissance des points de scission des tokens Cette étape demande une construction d'architecture complète pour résoudre ce problème, celui-ci n'ayant pas été abordé précédemment ainsi qu'un re-entraînement de la pipeline et l'ajout dans le corpus d'entraînement de manuscrits avec un type de chiffrement "machine".

Cette étape représente **5 semaines** de travail.

Implémentation du cross encoder L'architecture du cross encoder étant déjà documentée, le temps alloué à cette partie pourra être largement réduit. Cependant, elle demandera aussi un ré-entraînement du modèle ainsi que plusieurs modifications majeures de la structure pouvant induire des contretemps.

Cette étape représente **4 semaines** de travail.

Benchmarking Le benchmarking pourra être réalisé par la simple comparaison et documentation des performances des structures précédemment citées. Elle ne demande pas de réalisation technique particulière mais une profonde rigueur pour assurer une conclusion correcte.

Cette étape représente **1 semaine** de travail.

Ces estimations sont données à titre indicatif.

7 Limitations

Pour le moment, l'avancée du projet est grandement ralentie par des contraintes techniques quant à l'optimisation du modèle et la capacité de mémoire des serveurs.

L'amélioration de l'architecture nécessiterait un benchmarking de plusieurs approches, ce qui est grandement limité par le temps d'entraînement des modèles.

D'autre part, une dimension éthique est à prendre en compte, notamment au regard de la consommation d'énergie lors des entraînements des modèles. Il pourrait donc être intéressant de confronter le gain pour le propriétaire du modèle à la consommation du développement complet de la pipeline, en considérant les différents tests et le benchmarking.

8 Conclusion

Ce travail relève d'une première piste d'exploration pour solutionner la problématique relevée par l'équipe Caramba, spécialisée en cryptographie.

Le modèle existant ne présente pour le moment aucune contrainte technique majeure empêchant strictement son aboutissement et sa mise en service mais demande cependant encore un profond travail de restructuration, d'optimisation et d'approfondissement.

Ce travail représente donc une base pour une future reprise du projet.

A Déclaration d'utilisation d'outils d'intelligence artificielle

La création de ce projet a été partiellement assistée par Claude Code AI.

Ci-après la liste des tâches qui ont été réalisées avec l'appui d'un outil d'intelligence artificielle:

- Vérification de code (unicité des appels de process et des chemins / tests de compilation) et optimisation de la complexité.
- Vérification et résolution d'erreurs liées au serveur.
- Automatisation des corrections répétitives (structures incorrectes / chemins incorrects)
- Organisation et standardisation de la documentation (basée sur un raisonnement et une structure préalablement définie)

L'utilisation de ces outils est faite dans une démarche d'automatisation et de gain d'efficacité sur le développement du processus. Toute tâche impliquant du raisonnement a été exclue des tâches attribuées à l'outil. (Hormis les processus d'optimisation dû à un manque de compétences dans le domaine. Tous les commits liés à ces tâches sont explicités dans le dépôt Github (*Demande d'accès au repo nécessaire*) afin de pouvoir être vérifiés et corrigés si besoin par des développeurs compétents en la matière).

B Glossaire

Base de données/Coprus : Une base de donnée est une collection de données ayant un lien entre elles. Elle est construite dans le but de rassembler des données là où un corpus est construit pour une tâche précise. Il est construit pour répondre à un problème définit à l'avance.

.json : Le .json est un type de fichier qui permet d'organiser du texte et qui est facilement manipulable par ordinateur selon des règles préétablies et un système de querying.

Métadonnées : Informations complémentaires pour commenter, compléter un document. Agit parfois comme un descripteur des caractéristiques d'un objet.

Pipeline : Enchaînement de process opérés dans le cadre d'un programme informatique.

Ontologie : Carte mentale représentant les connaissances disponibles d'un objet ou concept.

Script : Enchaînement de lignes de code exécutables

Entraînement d'un modèle d'IA : Phase de la mise en place d'un modèle d'IA où on lui présente les objets qu'il devra reconnaître/classer avec ses métadonnées afin qu'il encode les caractéristiques de l'objet pour accomplir sa tâche.

Convergence d'un modèle d'IA : Moment où le modèle finit son entraînement. Le moment où il parvient à donner une réponse en lisant l'information contenue du/des neurones issus de la convergence des autres.

Indice de coïncidence : (IC) Probabilité que deux lettres prises au hasard dans le texte soient identiques.

CPU/GPU : Central Processing Unit et Graphic Processing Unit. La première est plus robuste mais ne permet pas de faire des actions en parallèle quand la seconde le peut.

Nomenclature : Référencement de liens entre un signifiant et un signifié.

Command Line Interface : (CLI) Interface permettant d'interagir avec un programme informatique en langage naturel et de lui donner des instructions?

Silhouette score : Analyse de la distance entre les objet aux sein d'un même cluster et entre différents clusters.

References

- Du, S., Zheng, S., Wang, Y., Bai, W., O'Regan, D. P., & Qin, C. (2024, July 10). TIP: Tabular-image pre-training for multimodal classification with incomplete data. <https://doi.org/10.48550/arXiv.2407.07582>
- Foxon, F. (2025). Supplemental materials for paper: Machine learning for text classification in classical cryptography. <https://doi.org/10.17605/OSF.IO/ZYMTD>
- Gao, B., & Pavel, L. (2018, August 21). On the properties of the softmax function with application in game theory and reinforcement learning. <https://doi.org/10.48550/arXiv.1704.00805>
- Lei, J., Chen, X., Zhang, N., Wang, M., Bansal, M., Berg, T. L., & Yu, L. (2022, March 10). LoopITR: Combining dual and cross encoder architectures for image-text retrieval. <https://doi.org/10.48550/arXiv.2203.05465>
- Megyesi, B., Esslinger, B., Fornés, A., Kopal, N., Láng, B., Lasry, G., Leeuw, K. D., Pettersson, E., Wacker, A., & Waldspühl, M. (2020). Decryption of historical manuscripts: The DECRYPT project. *Cryptologia*, 44(6), 545–559. <https://doi.org/10.1080/01611194.2020.1716410>
- Michelle Waldspühl, University of Oslo, Beáta Megyesi, Stockholm University, Alicia Fornés, Computer Vision Center, Universitat Autònoma de Barcelona, & Nils Kopal, University of Siegen. (n.d.). Grapholinguistic features of historical ciphers and challenges for computer-based transcription and cryptanalysis.
- Mikhalev, V., Kopal, N., Esslinger, B., Waldspühl, M., Láng, B., & Megyesi, B. (2023). What is the code for the code? historical cryptology terminology, 130–138. <https://doi.org/10.3384/ecp195702>
- Partin, L., Geraci, G., Rushdi, A. A., Eldred, M. S., & Schiavazzi, D. E. (2023). Multifidelity data fusion in convolutional encoder/decoder networks. *Journal of Computational Physics*, 472, 111666. <https://doi.org/10.1016/j.jcp.2022.111666>
- Reinares Guerreros, Alejandra, de Gregorio, Giuseppe, & Fornés, Alicia. (2026). Unsupervised feature learning via convolutional autoencoders for cross-manuscript comparison in historical cryptanalysis.
- Zhao, F., Zhang, C., & Geng, B. (2024). Deep multimodal data fusion. *ACM Computing Surveys*, 56(9), 1–36. <https://doi.org/10.1145/3649447>